Data Cleansing Retail Store Sales Menggunakan Microsoft Excel

(Tumpal Divito Siregar)

A. Gambaran Umum Proyek

Proyek *Data Cleansing Retail Store Sales* merupakan proyek pengolahan data yang bertujuan untuk meningkatkan kualitas *dataset* penjualan ritel melalui proses pemeriksaan dan pembersihan data. Dalam proses pengolahan data, ditemukan permasalahan yang dapat memengaruhi kualitas dan keakuratan informasi, seperti data kosong. Permasalahan tersebut perlu ditangani agar data dapat digunakan secara lebih optimal untuk kebutuhan analisis.

Proyek ini berfokus pada identifikasi permasalahan, penerapan teknik pembersihan data, serta validasi untuk memastikan bahwa data telah diperbaiki sesuai dengan kriteria yang ditentukan. Microsoft Excel digunakan sebagai perangkat utama dalam proses pengolahan, dengan memanfaatkan berbagai fungsi dan fitur yang mendukung kegiatan *data cleansing*.

Melalui proyek ini, diharapkan dapat dihasilkan *dataset* yang lebih bersih, konsisten, dan terstruktur sehingga siap digunakan untuk proses analisis data lebih lanjut. Selain itu, proyek ini menjadi sarana untuk menerapkan dan mengembangkan keterampilan dalam pengolahan data, khususnya pada tahap persiapan data sebelum dilakukan analisis.

B. Informasi Dataset

Dataset yang digunakan dalam proyek ini adalah *Dirty Retail Store Sales Dataset* yang diperoleh dari platform *Kaggle*. *Dataset* ini merupakan data sintetis (*synthetic data*) yang dirancang untuk merepresentasikan transaksi penjualan pada sebuah toko ritel.

Dataset tersebut terdiri dari 12.575 baris data dan 11 kolom yang memuat informasi terkait transaksi penjualan. Data mencakup delapan kategori produk dengan masing-masing kategori memiliki 25 jenis barang. Setiap barang memiliki harga yang bersifat tetap (*static price*).

Adapun rincian kolom pada dataset beserta tipe datanya disajikan pada Tabel 1.

Tabel 1. Struktur Kolom Dataset

No	Nama Kolom	Tipe Data	Keterangan	Banyak Nilai Unik
1	Transaction ID	Teks	ID unik transaksi	12575
2	Customer ID	Teks	ID pelanggan	25

No	Nama Kolom	Tipe Data	Keterangan	Banyak Nilai Unik
3	Category	Teks	Kategori produk	8
4	Item	Teks	Nama barang	200
5	Price Per Unit	Numerik	Harga satuan	25
6	Quantity	Numerik	Jumlah barang	10
7	Total Spent	Numerik	Total pembelian	227
8	Payment Method	Teks	Metode pembayaran	3
9	Location	Teks	Lokasi transaksi	2
10	Transaction Date	Tanggal	Tanggal transaksi	1114
11	Discount Applied	Boolean	Ada tidaknya diskon	2

Sejalan dengan tujuan penyusunannya, *dataset* ini dengan sengaja memuat sejumlah permasalahan kualitas data seperti nilai yang hilang (*missing values*). Permasalahan tersebut dirancang untuk merepresentasikan tantangan pengelolaan data pada situasi nyata, sehingga *dataset* ini sesuai dimanfaatkan sebagai media pembelajaran *data cleansing*.

C. Perangkat dan Teknologi yang Digunakan

Proyek *Data Cleansing Retail Store Sales* menggunakan Microsoft Excel sebagai alat bantu utama dalam proses pemeriksaan, pengolahan, dan pembersihan data. Pemilihan Excel didasarkan pada kelengkapan fungsi dan fiturnya yang mampu mengidentifikasi serta mengatasi persoalan kualitas data secara efisien.

Berikut fungsi dan fitur Excel yang diterapkan:

1. TRIM

   TRIM berfungsi untuk menghilangkan spasi berlebih pada teks, baik di bagian awal maupun akhir, sekaligus merapikan jarak antar kata. Langkah ini bertujuan menjaga keseragaman data dan mengurangi risiko inkonsistensi.
2. UNIQUE

   UNIQUE berfungsi untuk menampilkan seluruh nilai unik pada sebuah kolom, sehingga ketidakkonsistenan penulisan maupun kategori data dapat diidentifikasi dengan mudah.
3. COUNTA

   COUNTA berfungsi untuk menghitung jumlah sel yang tidak kosong (berisi data apa pun) dalam suatu rentang.

4. COUNTIF

   COUNTIF berfungsi untuk menghitung jumlah sel dalam suatu rentang yang memenuhi satu kriteria tertentu.

5. SUM

   SUM berfungsi untuk menjumlahkan angka dalam sel, rentang, atau nilai yang ditentukan.

6. VLOOKUP

   VLOOKUP berfungsi untuk mencari suatu nilai di kolom paling kiri sebuah tabel, lalu mengambil data dari kolom lain pada baris yang sama.

7. TRANSPOSE

   TRANSPOSE berfungsi untuk menukar orientasi data: baris menjadi kolom, dan kolom menjadi baris.

8. SORT

   SORT berfungsi untuk mengurutkan isi suatu rentang atau *array* secara otomatis (naik atau turun) dan menampilkan hasilnya di sel lain tanpa mengubah data asli.

9. FILTER

   FILTER berfungsi untuk menyaring data dari suatu rentang berdasarkan syarat tertentu, lalu menampilkan hanya baris (atau kolom) yang memenuhi syarat tersebut di sel lain.

10. INDEX

    INDEX berfungsi untuk mengambil nilai dari sel tertentu dalam suatu rentang berdasarkan nomor baris dan nomor kolomnya.

11. MATCH

    MATCH berfungsi untuk mencari posisi (urutan) suatu nilai di dalam rentang satu baris atau satu kolom. Hasilnya berupa angka posisi, bukan nilai datanya.

12. IF

    IF berfungsi untuk menguji suatu kondisi, lalu menampilkan satu hasil jika kondisinya benar (*TRUE*) dan hasil lain jika salah (*FALSE*).

13. IFERROR

    IFERROR berfungsi untuk menangkap error pada suatu rumus, lalu menggantinya dengan nilai atau teks yang ditentukan. Jika rumus tidak error, hasil aslinya tetap ditampilkan.

14. AND

    AND berfungsi untuk menguji beberapa kondisi sekaligus, dan menghasilkan *TRUE* hanya jika semua kondisi benar. Jika ada satu saja yang salah, hasilnya *FALSE*.

15. OR

    OR berfungsi untuk menguji beberapa kondisi sekaligus, dan menghasilkan *TRUE* jika salah satu (atau lebih) kondisi benar. Hasilnya *FALSE* hanya jika semua kondisi salah.

D. Pemeriksaan Kualitas Data

Pemeriksaan kualitas data merupakan tahap awal yang dilakukan untuk mengetahui kondisi *dataset* sebelum proses pembersihan dimulai. Tahap ini bertujuan mengidentifikasi berbagai permasalahan yang dapat memengaruhi keakuratan, konsistensi, dan kelengkapan data.

Pada proyek ini, pemeriksaan dilakukan terhadap setiap kolom dalam *dataset Retail Store Sales* untuk mengetahui karakteristik data serta menemukan nilai-nilai yang tidak sesuai. Beberapa aspek yang diperiksa meliputi:

1. Pemeriksaan Struktur dan Tipe Data

   Pemeriksaan struktur dan tipe data dilakukan untuk mengetahui karakteristik dasar *dataset*, meliputi jumlah baris, jumlah kolom, nama variabel, tipe data, serta banyaknya nilai unik pada setiap kolom. Pemeriksaan ini bertujuan untuk memahami struktur *dataset* dan memastikan bahwa setiap kolom memiliki tipe data yang sesuai dengan informasi yang direpresentasikan.

   Dataset Retail Store Sales yang digunakan dalam proyek ini memiliki 12.575 baris dan 11 kolom. Setiap kolom memiliki karakteristik yang berbeda, baik dari segi jenis informasi maupun variasi nilai yang terkandung di dalamnya. Untuk memberikan gambaran yang lebih jelas, hasil pemeriksaan struktur kolom dataset disajikan pada Tabel 1.

   Berdasarkan Tabel 1, terdapat empat jenis tipe data yang digunakan, yaitu teks, numerik, tanggal, dan Boolean. Kolom bertipe teks mencakup informasi identitas transaksi, pelanggan, kategori produk, nama barang, metode pembayaran, dan lokasi. Kolom numerik digunakan untuk merepresentasikan harga satuan, jumlah barang, dan total pembelian. Sementara itu, kolom tanggal digunakan untuk mencatat waktu transaksi, dan tipe Boolean digunakan untuk menunjukkan apakah suatu transaksi memperoleh diskon atau tidak.
2. Pemeriksaan Missing Values

   Pemeriksaan dilakukan untuk mengidentifikasi sel atau nilai yang kosong pada setiap kolom. Keberadaan nilai yang hilang perlu diperhatikan karena dapat memengaruhi proses pengolahan dan analisis data.
3. Pemeriksaan Data Duplikat

   Pemeriksaan dilakukan untuk mengetahui apakah terdapat baris data yang tercatat lebih dari satu kali. Data duplikat perlu ditinjau lebih lanjut untuk memastikan apakah pengulangan tersebut merupakan kesalahan pencatatan atau memang transaksi yang berbeda.

4. Pemeriksaan Inkonsistensi Data

   Pemeriksaan dilakukan dengan menampilkan nilai-nilai unik (*unique values*) pada setiap kolom yang relevan. Cara ini membantu mengidentifikasi perbedaan penulisan, penggunaan huruf kapital, spasi berlebih, kesalahan pengetikan (*typo*), serta format nilai yang tidak seragam.

E. Proses Pembersihan Data

Proses pembersihan data (*data cleansing*) dilakukan menggunakan Microsoft Excel dalam satu file kerja yang terdiri atas delapan lembar kerja (*worksheet*). Setiap lembar kerja memiliki fungsi dan tahapan pengolahan yang berbeda, mulai dari penyimpanan data mentah hingga menghasilkan dataset akhir yang telah dibersihkan.

Sheet pertama digunakan untuk menyimpan data mentah (*raw data*) yang diperoleh dari *Kaggle*. Data pada *sheet* ini dipertahankan sebagai sumber awal dan tidak mengalami perubahan secara langsung. Selanjutnya, proses pemeriksaan, pengolahan, dan perbaikan data dilakukan pada *sheet-sheet* berikutnya sesuai dengan permasalahan yang ditemukan.

Sheet kedelapan merupakan lembar kerja terakhir yang berisi dataset hasil pembersihan (*cleaned data*). Dataset ini diharapkan telah melalui serangkaian proses pemeriksaan dan perbaikan sehingga memiliki kualitas data yang lebih baik, konsisten, dan siap digunakan untuk analisis lebih lanjut.

Pembagian proses ke dalam delapan *sheet* bertujuan untuk memisahkan setiap tahapan pengerjaan, mempermudah pelacakan perubahan data, serta menjaga agar data mentah tetap tersedia sebagai pembanding terhadap hasil akhir.

1. Pembersihan Spasi Berlebih (*Trimming Data*)

   Tahap pertama dalam proses pembersihan data adalah menghilangkan spasi berlebih (*extra spaces*) pada setiap nilai dalam kolom *dataset*. Permasalahan spasi dapat ditemukan pada bagian awal teks (*leading spaces*), bagian akhir teks (*trailing spaces*), maupun spasi berulang di antara kata (*multiple spaces*).

   Keberadaan spasi yang tidak diperlukan dapat menyebabkan ketidaksesuaian dalam proses pencarian, pencocokan, pengelompokan, maupun perhitungan data. Sebagai contoh, nilai "Patisserie" dan "Patisserie " (dengan spasi di akhir) dapat dikenali sebagai dua nilai yang berbeda, meskipun keduanya merujuk pada barang yang sama.

   Untuk mengatasi permasalahan tersebut, digunakan fungsi “TRIM” pada Microsoft Excel. Fungsi ini bertujuan menghapus spasi di awal dan akhir teks serta mengurangi spasi berulang di antara kata menjadi satu spasi.

Adapun rumus yang digunakan adalah sebagai berikut:

$$= \text{TRIM}(\text{text})$$

Rumus tersebut diterapkan pada setiap kolom yang berisi data teks. Hasilnya kemudian digunakan sebagai data yang telah dibersihkan untuk tahapan pengolahan berikutnya.

Melalui proses ini, diharapkan seluruh nilai teks memiliki format penulisan yang lebih seragam sehingga dapat meminimalkan kesalahan dalam proses pencarian, pencocokan, dan pengelompokan data.

2. Identifikasi Kolom

Tahap selanjutnya adalah melakukan identifikasi terhadap beberapa kolom yang berisi informasi kategorikal dan identitas dalam dataset. Identifikasi ini dilakukan untuk mengetahui variasi nilai yang terdapat pada setiap kolom serta frekuensi kemunculan masing-masing nilai.

Proses identifikasi dilakukan menggunakan fungsi UNIQUE untuk memperoleh daftar nilai yang berbeda dan fungsi COUNTIF untuk menghitung frekuensi kemunculan setiap nilai. Hasil identifikasi kemudian disusun dalam bentuk tabel agar karakteristik masing-masing kolom lebih mudah diamati.

Adapun kolom yang menjadi fokus identifikasi meliputi Transaction ID, Customer ID, Category, Item, Payment Method, dan Location

a. Transaction ID

Kolom Transaction ID merupakan kolom yang berisi identitas unik untuk setiap transaksi. Identifikasi dilakukan untuk mengetahui apakah terdapat ID transaksi yang muncul lebih dari satu kali.

Untuk menghitung banyaknya nilai unik pada kolom ini, digunakan rumus Excel sebagai berikut:

```
=COUNTA(UNIQUE('Trim Semua Data'!A2:A12576))
```

Keterangan:

- UNIQUE('Trim Semua Data'!A2:A12576) digunakan untuk menghasilkan daftar nilai unik dari kolom Transaction ID pada sheet Trim Semua Data.

- COUNTA(...) digunakan untuk menghitung banyaknya nilai yang dihasilkan oleh fungsi UNIQUE.

Berdasarkan hasil perhitungan, diperoleh sebanyak 12.575 nilai unik, sama dengan jumlah keseluruhan baris pada dataset.

Hasil tersebut menunjukkan bahwa setiap transaksi memiliki ID yang berbeda dan tidak ditemukan ID transaksi yang berulang. Dengan demikian, berdasarkan identitas transaksi, tidak terdapat indikasi duplikasi ID pada dataset.

b. Customer ID

Kolom Customer ID berisi identitas pelanggan yang melakukan transaksi. Identifikasi dilakukan untuk mengetahui jumlah pelanggan yang berbeda serta frekuensi transaksi yang dilakukan oleh masing-masing pelanggan.

Dalam proses ini, dibuat sebuah tabel yang terdiri atas dua kolom, yaitu Nilai Unik: Menampilkan seluruh ID pelanggan yang berbeda, dan Banyak Data: Menampilkan frekuensi kemunculan masing-masing ID pelanggan dalam dataset. Adapun rumus yang digunakan adalah sebagai berikut:

- Nilai Unik
  =UNIQUE('Trim Semua Data'!B2:B12576)

  Rumus tersebut digunakan untuk menghasilkan daftar ID pelanggan yang berbeda tanpa menampilkan nilai yang sama secara berulang.

- Banyak Data
  =COUNTIF('Trim Semua Data'!$B$2:$B$12576,'Identifikasi Kolom'!A11)

  Rumus COUNTIF digunakan untuk menghitung berapa kali suatu ID pelanggan muncul dalam seluruh data transaksi. Dalam rumus tersebut:
  - 'Trim Semua Data'!$B$2:$B$12576 erupakan rentang data yang akan diperiksa.
  - 'Identifikasi Kolom'!A11 merupakan kriteria berupa ID pelanggan yang akan dihitung frekuensi kemunculannya.

Berdasarkan hasil identifikasi, diperoleh sebanyak 25 nilai unik, yang menunjukkan bahwa terdapat 25 pelanggan berbeda dalam dataset. Tabel

frekuensi juga memberikan informasi mengenai banyaknya transaksi yang dilakukan oleh masing-masing pelanggan.

c. Category

Kolom Category berisi informasi mengenai kategori produk yang terdapat dalam dataset. Identifikasi dilakukan untuk mengetahui seluruh kategori produk yang tersedia beserta frekuensi kemunculan masing-masing kategori.

Sama seperti identifikasi pada kolom Customer ID, proses ini menggunakan tabel yang terdiri atas dua kolom, yaitu Nilai Unik dan Banyak Data.

- Nilai Unik

```
=UNIQUE('Trim Semua Data'!C2:C12576)
```

Rumus tersebut digunakan untuk menampilkan seluruh kategori produk yang berbeda.

- Banyak Data

```
=COUNTIF('Trim Semua Data'!$C$2:$C$12576,'Identifikasi Kolom'!A41)
```

Rumus tersebut digunakan untuk menghitung jumlah kemunculan setiap kategori produk dalam dataset.

Berdasarkan hasil identifikasi, diperoleh sebanyak 8 nilai unik pada kolom Category. Hasil ini sesuai dengan informasi yang tercantum pada deskripsi dataset *Kaggle*, yaitu terdapat delapan kategori produk.

d. Item

Kolom Item berisi informasi mengenai nama barang yang terdapat dalam transaksi penjualan. Identifikasi dilakukan untuk mengetahui daftar barang yang tersedia, frekuensi kemunculan setiap barang, serta harga satuan masing-masing barang.

Pada kolom ini, tabel identifikasi dibuat dengan tiga kolom, yaitu Nilai Unik, Banyak Data, dan Price Per Unit (harga satuan). Adapun rumus yang digunakan adalah sebagai berikut:

- Nilai Unik

```
=UNIQUE('Trim Semua Data'!D2:D12576)
```

Rumus tersebut digunakan untuk menampilkan seluruh nama barang yang berbeda pada kolom Item.

- Banyak Data

  =COUNTIF('Trim Semua Data'!$D$2:$D$12576,'Identifikasi Kolom'!A54)

  Rumus tersebut digunakan untuk menghitung berapa kali setiap nama barang muncul dalam dataset.

- Price Per Unit

  =VLOOKUP(A54,'Trim Semua Data'!$D$2:$E$12576,2,FALSE)

  Rumus VLOOKUP digunakan untuk mencari harga satuan berdasarkan nama barang. Penjelasan setiap argumennya adalah sebagai berikut:
  - A54 merupakan nilai yang dicari, yaitu nama barang.
  - 'Trim Semua Data'!$D$2:$E$12576 merupakan tabel referensi yang terdiri atas kolom Item dan Price Per Unit.
  - 2 menunjukkan bahwa nilai yang dikembalikan berasal dari kolom kedua tabel referensi, yaitu Price Per Unit.
  - FALSE digunakan untuk melakukan pencarian dengan kecocokan tepat (*exact match*).

Berdasarkan hasil identifikasi, diperoleh sebanyak 201 nilai unik pada kolom Item. Namun, jumlah tersebut tidak sesuai dengan informasi pada deskripsi dataset *Kaggle* yang menyatakan bahwa terdapat 200 jenis barang.

Setelah dilakukan pemeriksaan lebih lanjut, ditemukan bahwa salah satu nilai unik tersebut merupakan sel kosong (*blank cell*). Dengan demikian, jumlah nama barang yang sebenarnya adalah 200 jenis, sedangkan satu nilai lainnya merupakan representasi dari data kosong.

Selain itu, berdasarkan hasil penjumlahan frekuensi kemunculan seluruh nama barang, diperoleh total sebanyak 11.362 data. Jumlah tersebut lebih sedikit dibandingkan dengan keseluruhan baris dataset, yaitu 12.575 baris. Hal

ini mengindikasikan adanya nilai kosong pada kolom Item yang perlu ditangani pada tahap pembersihan data berikutnya.

e. Payment Method

Kolom Payment Method berisi informasi mengenai metode pembayaran yang digunakan pelanggan dalam melakukan transaksi. Identifikasi dilakukan dengan membuat tabel yang terdiri atas dua kolom, yaitu Nilai Unik dan Banyak Data, sebagaimana diterapkan pada kolom sebelumnya.

Berdasarkan hasil identifikasi, diperoleh sebanyak 3 nilai unik pada kolom Payment Method. Hasil tersebut menunjukkan bahwa terdapat tiga jenis metode pembayaran yang digunakan dalam transaksi pada dataset.

f. Location

Kolom Location berisi informasi mengenai lokasi transaksi. Identifikasi dilakukan menggunakan metode yang sama seperti kolom Payment Method, yaitu dengan menyusun daftar nilai unik beserta frekuensi kemunculan masing-masing nilai.

Berdasarkan hasil identifikasi, diperoleh sebanyak 2 nilai unik pada kolom Location. Hal ini menunjukkan bahwa transaksi dalam dataset berasal dari dua lokasi yang berbeda.

3. Membandingkan Kolom Category dengan Kolom Item

Pada tahap ini dilakukan identifikasi hubungan antara kolom Category dan kolom Item. Dibuat sebuah tabel bantu dengan 8 kolom, yang judul kolomnya merupakan seluruh kategori produk dari kolom Category. Nilai pada setiap kolom berupa daftar item produk dari kolom Item yang termasuk dalam kategori tersebut. Pengisian nilai dilakukan menggunakan rumus berikut:

```
= SORT(UNIQUE(FILTER('Trim Semua Data'!$D$2:$D$12576, ('Trim Semua Data'!$C$2:$C$12576
                = A$1) * ('Trim Semua Data'!$D$2:$D$12576 <> "")))
```

Rumus tersebut digunakan untuk memperoleh daftar nama barang berdasarkan kategori tertentu. Proses ini dilakukan dengan menyaring data sesuai kategori, mengabaikan sel kosong, menghapus data duplikat, serta mengurutkan nama barang secara alfabetis. Hasilnya berupa daftar nama barang unik untuk setiap kategori, sebagaimana ditunjukkan pada potongan tabel berikut.

Tabel 2. Category - Item

Patisserie	Milk Products	Butchers	...
Item_1_PAT	Item_1_MILK	Item_1_BUT	...
Item_10_PAT	Item_10_MILK	Item_10_BUT	...
Item_11_PAT	Item_11_MILK	Item_11_BUT	...

Patisserie	Milk Products	Butchers	...
⋮	⋮	⋮	⋮
Item_9_PAT	Item_9_MILK	Item_9_BUT	...

Selanjutnya, pada worksheet yang sama, dibuat tabel bantu baru yang berfungsi untuk menampilkan jumlah item pada setiap kategori dengan menggunakan rumus berikut:

$$= \text{COUNTIF}('\text{Trim Semua Data}'!\$D\$2:\$D\$12576, '\text{Category X Item}'!A31)$$

Rumus tersebut digunakan untuk menghitung jumlah kemunculan nama barang tertentu pada kolom D di worksheet Trim Semua Data. Dengan demikian, diperoleh jumlah kemunculan setiap nama barang dalam keseluruhan data yang telah dibersihkan seperti potongan tabel berikut

Tabel 3 Total Item

Patisserie	Total	Milk Products	Total	...
Item_1_PAT	62	Item_1_MILK	109	...
Item_10_PAT	29	Item_10_MILK	9	...
Item_11_PAT	95	Item_11_MILK	106	...
⋮		⋮		⋮
Item_9_PAT	54	Item_9_MILK	10	...

Selanjutnya, berdasarkan Tabel 3, dilakukan penjumlahan jumlah seluruh item pada masing-masing kategori. Hasil penjumlahan tersebut kemudian dibandingkan dengan jumlah kemunculan setiap kategori yang telah diperoleh pada tahap identifikasi kolom sebelumnya. Perbandingan ini bertujuan untuk mengetahui jumlah data kosong pada setiap kategori. Hasilnya disajikan pada tabel berikut.

Tabel 4. Data Kosong Setiap Kategori

Kategori	Banyak Data Kosong
Patisserie	159
Milk Products	159
Butchers	147
Beverages	140
Food	162
Furniture	131
Electric household essentials	154
Computers and electric accessories	161

4. Membandingkan Kolom Item dengan Kolom Price Per Unit

Tahap ini dilakukan untuk memastikan bahwa setiap item memiliki satu nilai harga yang konsisten dan tidak terdapat perbedaan harga untuk nama item yang sama.

Dengan demikian, setiap item hanya memiliki satu harga yang menjadi acuan dalam proses pengolahan data selanjutnya. Pemeriksaan ini juga bertujuan untuk menghindari ketidakkonsistenan data harga yang dapat memengaruhi ketepatan hasil analisis.

5. Imputasi Kolom Item

Berdasarkan hasil pemeriksaan sebelumnya, diketahui bahwa kolom yang mengandung *missing values* adalah kolom Item. Oleh karena itu, tahap selanjutnya difokuskan pada pengisian nilai kosong pada kolom tersebut. Dalam proses ini, digunakan lima kolom, yaitu satu kolom target (Item) dan empat kolom bantu (Category, Price Per Unit, Quantity, dan Total Spent).

Sebagai catatan, nilai pada kolom Total Spent merupakan hasil perkalian antara Price Per Unit dan Quantity,

$$\text{Total Spent} = \text{Price Per Unit} \times \text{Quantity}$$

atau

$$\text{Price Per Unit} = \frac{\text{Total Spent}}{\text{Quantity}}.$$

Untuk membantu proses identifikasi nama Item yang masih kosong, seluruh nilai pada kolom Price Per Unit terlebih dahulu dikosongkan. Langkah ini dilakukan karena ditemukan beberapa transaksi yang memiliki nilai Quantity dan Total Spent, tetapi tidak memiliki nilai Price Per Unit. Padahal, harga satuan sebenarnya dapat diperoleh dengan membagi Total Spent dengan Quantity.

Selanjutnya, dilakukan pengisian kembali kolom Price Per Unit menggunakan rumus dengan ketentuan bahwa apabila kedua kolom, yaitu Quantity dan Total Spent, memiliki nilai, maka harga satuan dihitung dari hasil pembagian Total Spent dengan Quantity. Sebaliknya, apabila salah satu atau kedua kolom tersebut kosong, hasil yang ditampilkan adalah sel kosong (*blank*).

Dengan demikian, nilai pada kolom Price Per Unit hanya akan tersedia apabila data Quantity dan Total Spent keduanya lengkap. Informasi harga satuan yang diperoleh kemudian digunakan sebagai salah satu acuan tambahan dalam proses identifikasi dan pengisian nama Item yang kosong. Hal ini memungkinkan proses imputasi dilakukan dengan mempertimbangkan kesesuaian kategori dan harga satuan berdasarkan informasi transaksi yang tersedia.

Pada tahap berikutnya, seluruh nilai pada kolom Item sengaja dikosongkan terlebih dahulu untuk dilakukan proses imputasi ulang. Pengisian kembali nama Item dilakukan dengan memanfaatkan dua kolom utama sebagai acuan pencocokan, yaitu Category dan Price Per Unit. Kedua kolom tersebut digunakan karena setiap item memiliki

kategori dan harga satuan yang dapat dijadikan karakteristik untuk mengidentifikasi nama barang yang sesuai.

Proses imputasi dilakukan dengan mencocokkan kombinasi nilai Category dan Price Per Unit pada setiap baris transaksi dengan tabel referensi yang terdapat pada *worksheet* Item X Price Per Unit. Tabel referensi tersebut memuat informasi nama Item beserta kategori dan harga satuannya. Dengan menggunakan kombinasi kedua atribut tersebut, diharapkan nama Item yang kosong dapat diidentifikasi berdasarkan kesesuaian data transaksi dengan informasi pada tabel referensi.

Secara lebih rinci, rumus yang digunakan bekerja melalui beberapa tahapan sebagai berikut.

a. Pemeriksaan kelengkapan data

   Tahap pertama menggunakan fungsi OR untuk memeriksa apakah kolom Category atau Price Per Unit kosong. Apabila salah satu dari kedua kolom tersebut tidak memiliki nilai, rumus akan menghasilkan teks kosong (*blank*). Hal ini dilakukan karena proses pencocokan membutuhkan kedua informasi tersebut. Tanpa salah satunya, identifikasi nama Item tidak dapat dilakukan secara optimal.

b. Penyeragaman teks kategori

   Fungsi TRIM digunakan untuk menghilangkan spasi berlebih pada nilai Category, baik spasi di awal maupun di akhir teks. Langkah ini diperlukan agar perbedaan penulisan yang disebabkan oleh spasi tidak mengganggu proses pencocokan dengan tabel referensi.

c. Pembentukan kunci pencocokan (*key*)

   Nilai Category dan Price Per Unit digabungkan menggunakan operator penggabung teks (&), dengan karakter pemisah berupa tanda garis vertikal(|) . Penggabungan ini dilakukan untuk membentuk satu kunci pencocokan berdasarkan kombinasi kedua atribut tersebut.

   Langkah serupa juga diterapkan pada tabel referensi, sehingga setiap baris transaksi memiliki kunci pencocokan yang dapat dibandingkan dengan kunci pada tabel referensi.

d. Pencarian posisi data menggunakan MATCH

   Fungsi MATCH digunakan untuk mencari posisi kunci pencocokan dari data transaksi pada kumpulan kunci yang telah dibentuk dari tabel referensi. Argumen terakhir bernilai 0, yang berarti pencarian dilakukan dengan metode pencocokan tepat (*exact match*). Dengan demikian, hasil pencarian hanya akan diterima apabila kombinasi Category dan Price Per Unit ditemukan secara identik pada tabel referensi.

e. Pengambilan nama Item menggunakan INDEX

Setelah posisi data yang sesuai ditemukan oleh MATCH, fungsi INDEX digunakan untuk mengambil nama Item berdasarkan posisi tersebut pada kolom nama barang di tabel referensi. Dengan demikian, nama Item yang dihasilkan merupakan nama barang yang memiliki kombinasi kategori dan harga satuan yang sesuai dengan data transaksi.

f. Penanganan data yang tidak ditemukan

Fungsi IFERROR digunakan untuk menangani kondisi ketika proses pencarian tidak menemukan kombinasi Category dan Price Per Unit yang sesuai pada tabel referensi. Apabila kondisi tersebut terjadi, rumus akan menampilkan keterangan "Tidak ditemukan" alih-alih menghasilkan pesan kesalahan Excel.

Dengan mekanisme tersebut, proses imputasi nama Item dilakukan berdasarkan pencocokan dua atribut sekaligus, bukan hanya berdasarkan kategori barang. Pendekatan ini diharapkan dapat meningkatkan ketepatan identifikasi nama barang, terutama ketika dalam satu kategori terdapat beberapa item dengan nama yang berbeda. Namun, keberhasilan pencocokan tetap bergantung pada kelengkapan dan konsistensi informasi pada tabel referensi serta keunikan kombinasi kategori dan harga satuan yang digunakan.

Setelah seluruh tahapan imputasi dilakukan, diperoleh hasil pengisian kembali pada kolom Item berdasarkan informasi Category dan Price Per Unit. Dengan demikian, setiap baris yang memiliki nilai Item dipastikan juga memiliki nilai pada kedua kolom acuan tersebut. Sebaliknya, apabila salah satu dari kedua kolom tersebut tidak memiliki nilai, kolom Item akan tetap dikosongkan.

Berdasarkan hasil akhir proses ini, diperoleh data Item yang telah diperbarui dengan jumlah sel kosong (*blank*) yang tersisa sebanyak 604 data. Nilai kosong tersebut merupakan data yang belum dapat diidentifikasi melalui kombinasi kategori dan harga satuan yang digunakan dalam proses pencocokan.

6. Penghapusan Data yang Tidak Dapat Diinputasi

Berdasarkan hubungan antarvariabel, nilai Total Spent diperoleh dari perkalian Quantity dengan Price Per Unit, sedangkan nilai Price Per Unit berkaitan langsung dengan Item yang diperjualbelikan. Oleh karena itu, apabila nama Item tidak dapat diidentifikasi, informasi transaksi tersebut menjadi kurang bermanfaat untuk analisis lebih lanjut, terutama analisis yang melibatkan jenis barang dan harga satuannya.

Atas pertimbangan tersebut, sebanyak 604 baris data yang masih memiliki nilai kosong pada kolom Item akan dihapus dari *dataset*. Keputusan ini juga didasarkan pada proporsi data kosong yang relatif kecil, yaitu sekitar 4,8% dari total 12.575 baris data.

Dengan menghapus baris tersebut, diharapkan diperoleh dataset yang lebih lengkap dan konsisten sehingga dapat digunakan untuk tahapan analisis berikutnya tanpa melibatkan transaksi yang identitas barangnya belum dapat dipastikan.

7. Data Bersih

   Setelah seluruh baris yang memiliki nilai kosong pada kolom Item dihapus, diperoleh dataset akhir yang terdiri atas 11.971 baris data. Dengan demikian, dari total 12.575 baris data awal, sebanyak 604 baris telah dieliminasi karena nama Item tidak berhasil diidentifikasi melalui proses imputasi sebelumnya.

   Penghapusan tersebut dilakukan untuk memastikan bahwa setiap transaksi dalam dataset akhir memiliki informasi nama barang yang jelas. Hal ini penting karena identitas Item merupakan salah satu variabel utama yang digunakan dalam proses analisis penjualan. Tanpa informasi tersebut, transaksi akan sulit diklasifikasikan berdasarkan jenis barang, sehingga berpotensi mengurangi ketepatan hasil analisis.

   Selain itu, penghapusan baris dengan nilai Item yang kosong juga membantu menjaga konsistensi hubungan antarvariabel, khususnya antara Item, Price Per Unit, Quantity, dan Total Spent. Dengan demikian, setiap transaksi yang dipertahankan memiliki informasi yang lebih lengkap dan dapat digunakan untuk mendukung berbagai analisis selanjutnya.

   Berdasarkan hasil tersebut, dataset yang semula terdiri atas 12.575 baris berhasil diseleksi menjadi 11.971 baris data bersih. Dataset inilah yang selanjutnya digunakan sebagai dasar dalam proses eksplorasi dan analisis data (*Exploratory Data Analysis*/EDA).

F. Kesimpulan

Berdasarkan seluruh tahapan yang telah dilakukan dalam proyek *Data Cleansing* ini, dapat disimpulkan bahwa proses pembersihan data merupakan tahap penting dalam mempersiapkan dataset sebelum digunakan untuk analisis lebih lanjut. Dataset awal yang diperoleh dari *Kaggle* terdiri atas 12.575 baris dan 11 kolom, yang merepresentasikan data transaksi penjualan ritel. Dalam proses pemeriksaan awal, ditemukan permasalahan kualitas data, terutama nilai kosong (*missing values*) pada kolom Item yang berpotensi menyebabkan ketidakkonsistenan dalam pengolahan data.

Proses pembersihan diawali dengan menghilangkan spasi berlebih pada kolom-kolom bertipe teks menggunakan fungsi TRIM. Selanjutnya, dilakukan identifikasi terhadap nilai unik dan frekuensi kemunculan data pada beberapa kolom, seperti Transaction ID, Customer ID, Category, Item, Payment Method, dan Location. Tahapan ini membantu memahami karakteristik dataset sekaligus mengidentifikasi permasalahan yang perlu ditangani lebih lanjut. Selain itu, dilakukan pemeriksaan hubungan antara kolom

Category dan Item untuk mengetahui distribusi barang pada setiap kategori, serta pemeriksaan hubungan antara Item dan Price Per Unit untuk memastikan bahwa setiap barang memiliki harga satuan yang konsisten.

Permasalahan utama pada proyek ini adalah nilai kosong pada kolom Item. Untuk mengatasinya, dilakukan proses imputasi dengan memanfaatkan kombinasi informasi Category dan Price Per Unit sebagai acuan pencocokan terhadap tabel referensi. Sebelum proses imputasi dilakukan, nilai Price Per Unit dihitung kembali berdasarkan hubungan antara Total Spent dan Quantity, sehingga informasi harga satuan yang sebelumnya kosong dapat diperoleh apabila kedua variabel tersebut tersedia. Selanjutnya, nama Item diidentifikasi menggunakan kombinasi kategori dan harga satuan melalui fungsi INDEX, MATCH, TRIM, IF, OR, dan IFERROR. Melalui pendekatan tersebut, sebagian nilai Item yang sebelumnya kosong berhasil diidentifikasi dan diisi kembali.

Setelah proses imputasi selesai, masih terdapat 604 baris data yang memiliki nilai kosong pada kolom Item. Karena identitas barang merupakan informasi penting untuk analisis transaksi berdasarkan jenis produk, seluruh baris tersebut kemudian dihapus dari dataset. Jumlah data yang dihapus setara dengan sekitar 4,8% dari keseluruhan data awal. Dengan demikian, diperoleh dataset akhir sebanyak 11.971 baris dari sebelumnya 12.575 baris.

Secara keseluruhan, proyek ini berhasil menghasilkan dataset yang lebih bersih, konsisten, dan terstruktur melalui serangkaian proses pemeriksaan, identifikasi, imputasi, serta penghapusan data yang tidak dapat diperbaiki. Penggunaan Microsoft Excel beserta berbagai fungsi dan fiturnya menunjukkan bahwa proses data cleansing dapat dilakukan secara sistematis tanpa harus menggunakan perangkat lunak pengolahan data yang lebih kompleks. Selain menghasilkan dataset yang siap digunakan untuk tahap *Exploratory Data Analysis* (EDA), proyek ini juga memberikan pengalaman praktis dalam menerapkan teknik pengolahan data, memahami hubungan antarvariabel, serta menentukan pendekatan yang sesuai dalam menangani permasalahan kualitas data.